

# Modelo de riesgos proporcionales

Giancarlo Sal y Rosas

Departamento de Ciencias  
Pontificia Universidad Católica del Perú

May 5, 2017



# Outline

- 1 Modelo
- 2 Interpretación
- 3 Estimación del riesgo basal



# Modelo

- El modelo de riesgos proporcionales (PH) tiene la forma

$$\lambda(t | Z) = \lambda_0(t) \exp [Z^t \beta]$$

donde  $\lambda_0$  es una función de riesgo basal (es decir no depende de covariables)

- El modelo tambien se puede expresar como

$$\log [\lambda(t | Z)] = \log [\lambda_0(t)] + Z^t \beta$$

es decir el logaritmo de la función de riesgo en el tiempo  $T = t$  es una función lineal de las covariables.



# Modelo

- El modelo Exponencial es un caso particular

$$\lambda_0(t) = 1$$

es decir el riesgo basal es constante.

- El modelo Weibull es otro caso particular

$$\lambda_0(t) = at^{a-1}$$

- El modelo log logístico no es un caso particular del modelo PH



# Modelo

- La verosimilitud del model PH tiene la forma

$$\begin{aligned}L_n(\beta, \lambda_0) &= \prod_{i=1}^n f(x_i | Z_i)^{\delta_i} S(x_i | Z_i)^{1-\delta_i} \\&= \prod_{i=1}^n \lambda(x_i | Z_i)^{\delta_i} S(x_i | Z_i) \\&= \prod_{i=1}^n [\lambda_0(x_i) e^{Z_i^t \beta}]^{\delta_i} \exp \left[ - \int_0^{x_i} \lambda_0(t) e^{Z_i(t) \beta} dt \right] \end{aligned}$$

donde  $\beta \in R^k$  ( $k = \#$  de covariables) y  $\lambda_0$  pertenece a un espacio de funciones

- Optimizar (1) es un problema muy complicado dada la naturaleza de  $\lambda_0$



# Modelo: Verosimilitud parcial

- Cox (1972) descompuso la verosimilitud total en la forma

$$L_n(\beta, \lambda_0) = L_p(\beta) \times L_{resto}(\lambda_0, \beta)$$

y llama a  $L_p$  la "**verosimilitud parcial**"

- Cox (1972) afirmo que bastaba usar  $L_p(\beta)$  para estimar los coeficientes de regresión:

$$L_p(\beta) = \prod_{i=1}^m \frac{\exp[Z_i^t \beta]}{\sum_{j \in R(t_i)} \exp[Z_j^t \beta]}$$

donde  $R(t_i)$  es el conjunto de individuos que estan en riesgo en el el tiempo  $t_i$  y  $m$  es el número de eventos observados.



# Historia

- En 1972, Sir David Cox (no era Sir aun) publicó su artículo: **Regression models and life tables** en el Journal of the Royal Statistical Society
- Este fue leído ante la Royal Statistical Society el 8 de marzo de 1972
- En este artículo, Cox discute modelos de regresión para datos censurados y como tablas de vida son un caso particular de estos. En este proceso introduce el concepto de **verosimilitud parcial**
- En el artículo original se incluyen opiniones de Peto, Oakes, Barton, Prentice, Kalbfleisch, Breslow, entre otros.



# Historia

- La idea de **verosimilitud parcial** consiste en usar solo parte de la data para estimar los parámetros de regresión del modelo PH.
- En 1975, en su artículo **Partial Likelihood**, Cox fundamenta y formaliza su idea de **verosimilitud parcial** (pero sin mucho detalle ...)
- En 1981, Tsiatis en su artículo **A large sample study of the Cox regression model** publica una prueba rigurosa que el estimador de los coeficientes de regresión obtenido via la verosimilitud parcial **converge** al valor real de estos.





# Historia

- David Cox ha recibido innumerables premios por su trayectoria como estadístico entre los cuales podemos mencionar:
  - Guy Medals in Silver y Gold (1961 y 1963) de la Royal Statistical Society
  - Nombrado caballero por la reina Elizabeth en 1985
  - Miembro asociado extranjero de la academia nacional de ciencias de los EU
  - Miembro de la Royal Danish Academy of Sciences and Letters
  - Honorary Fellow de la Academia Británica en el 2000



# Interpretación: Variable binaria

- Nuestro modelo univariado es de la forma

$$\lambda(t | Z) = \lambda_0(t) e^{\beta Z}$$

- En el caso de una variable binaria (Ejemplo: sexo) tenemos

$$\frac{\lambda(t | Z = \text{hombre})}{\lambda(t | Z = \text{mujer})} = \frac{\lambda_0(t) e^{\beta \times 1}}{\lambda_0(t) e^{\beta \times 0}} = e^{\beta}$$

- **Interpretación:** El riesgo de desarrollar el evento en hombres es  $e^{\beta}$  veces el riesgo de desarrollar el evento en mujeres



# Regresión: Variable binaria

## ● Código de R

```
> modell <- coxph(Surv(time,status)~sex,data=cancer)
> summary(modell)
Call:
coxph(formula = Surv(time, status) ~ sex, data = cancer)

n= 228, number of events= 165

      coef exp(coef) se(coef)      z Pr(>|z|)
sex -0.5310    0.5880   0.1672 -3.176  0.00149 **

      exp(coef) exp(-coef) lower .95 upper .95
sex           0.588      1.701   0.4237   0.816

Concordance= 0.579 (se = 0.022 )
Rsquare= 0.046 (max possible= 0.999 )
Likelihood ratio test= 10.63 on 1 df, p=0.001111
Wald test               = 10.09 on 1 df, p=0.001491
Score (logrank) test = 10.33 on 1 df, p=0.001312
```

## ● Modelo PH tiene la forma

$$\lambda(t) = \lambda_0(t)e^{-0.53Z}$$

donde  $Z = 0$  (1) si la persona es hombre (mujer)



# Regresión: Variable binaria

- Intervalo de confianza para  $\hat{\beta}$

```
> confint(model1)
      2.5 %      97.5 %
sex -0.8586875 -0.2033595
```

- Intervalo de confianza para el cociente de riesgos:  $e^{\hat{\beta}}$

```
> exp(confint(model1))
      2.5 %      97.5 %
sex 0.4237178 0.8159848
```

- Interpretación:** Tengo un 95% de confianza que la diferencia en el riesgo en mujeres (en comparación con hombres) se encuentra entre una reducción del 18% y 58%



# Interpretación: Variable politómica

## • Código de R

```
> cancer$ph.ecog <- ifelse(cancer$ph.ecog < 2, cancer$ph.ecog, 2)
> model2 <- coxph(Surv(time, status) ~ factor(ph.ecog), data=cancer)
> summary(model2)
```

```
n= 227, number of events= 164
(1 observation deleted due to missingness)
```

	coef	exp(coef)	se(coef)	z	Pr(> z )
<b>factor</b> (ph.ecog) 1	0.3682	1.4451	0.1987	1.853	0.0638 .
<b>factor</b> (ph.ecog) 2	0.9309	2.5369	0.2235	4.166	3.11e-05 ***

	exp(coef)	exp(-coef)	lower .95	upper .95
<b>factor</b> (ph.ecog) 1	1.445	0.6920	0.9791	2.133
<b>factor</b> (ph.ecog) 2	2.537	0.3942	1.6371	3.931

## • Modelo PH tiene la forma

$$\lambda(t) = \lambda_0(t)e^{0.37Z_1 + 0.93Z_2}$$

donde  $Z_i = 1$  (0) si la persona tuvo un score ECOG igual a  $i$  (o no)



# Interpretación: Variable politómica

- Persona con score 1 vs. score 0

$$\frac{\lambda(t \mid Z = 1)}{\lambda(t \mid Z = 0)} = \frac{\lambda_0(t)e^{0.37 \times 1 + 0.93 \times 0}}{\lambda_0(t)e^{0.37 \times 0 + 0.93 \times 0}} = e^{0.37} = 1.4$$

**Interpretación:** Pacientes cuyo score ECOG fue 1, tiene 40% mayor riesgo de morir que aquellos que tuvieron score ECOG igual a 0.

- Persona con score 2 o 3 vs. score 0

$$\frac{\lambda(t \mid Z = 2, 3)}{\lambda(t \mid Z = 0)} = \frac{\lambda_0(t)e^{0.37 \times 0 + 0.93 \times 1}}{\lambda_0(t)e^{0.37 \times 0 + 0.93 \times 0}} = e^{0.93} = 2.5$$

**Interpretación:** Pacientes cuyo score ECOG fue 2 o 3, tiene 2.5 veces el riesgo de morir que pacientes cuyo score ECOG igual a 0.



# Regresión: Variable politómica

## ● Intervalos de confianza

```
> confint(model2)
                2.5 %      97.5 %
factor(ph.ecog) 1 -0.02117005 0.7575425
factor(ph.ecog) 2  0.49292109 1.3689575
> exp(confint(model2))
                2.5 %      97.5 %
factor(ph.ecog) 1 0.9790525 2.133028
factor(ph.ecog) 2 1.6370913 3.931250
```

## ● Interpretación:

- Pacientes cuyo score ECOG fue 2 o 3, tiene 2.5 veces el riesgo riesgo de morir que aquellos que tuvieron score ECOG igual a 0. Con una confianza del 95%, esta diferencia podría estar entre 1.6 y 3.9 veces.
- No tenemos evidencia, con una significancia del 5% , para afirmar que un score ECOG 1 incrementa el riesgo de muerte en comparación con un score ECOG de 0 (95%IC: 0.97-2.13)



# Interpretación: Variable politómica

- Deseamos comparar el riesgo entre pacientes con score ECOG 1 vs. pacientes con score ECOG 2 o 3:

$$\begin{aligned}\frac{\lambda(t \mid Z = 2, 3)}{\lambda(t \mid Z = 1)} &= \frac{\lambda_0(t)e^{0.37 \times 0 + 0.93 \times 1}}{\lambda_0(t)e^{0.37 \times 1 + 0.93 \times 0}} \\ &= e^{0.93 - 0.37} = e^{0.56} = 1.75\end{aligned}$$

- **Interpretación:** Pacientes cuyo score ECOG fue 2 o 3, tiene 1.8 veces el riesgo de morir que pacientes cuyo score ECOG igual a 1.





# Interpretación: Variable politómica

- **R** nos entrega la matriz de varianza covarianza de los coeficientes de regresión.

```
> model2$var
      [,1]      [,2]
[1,] 0.03946374 0.02734994
[2,] 0.02734994 0.04994456
```

$$\begin{aligned} \text{Var}(\hat{\beta}_3 - \hat{\beta}_2) &= \text{Var}(\hat{\beta}_3) + \text{Var}(\hat{\beta}_2) - \text{Cov}(\hat{\beta}_3, \hat{\beta}_2) \\ &= 0.05 + 0.04 - 0.03 = 0.06 \end{aligned}$$

- El intervalo de confianza al 95%, para el CRI, es

```
> c(0.56 - 1.96*sqrt(0.06), 0.56 + 1.96*sqrt(0.06))
[1] 0.07990001 1.04009999
> exp(c(0.56 - 1.96*sqrt(0.06), 0.56 + 1.96*sqrt(0.06)))
[1] 1.083179 2.829500
```

Interpretación: Tengo un 95% de confianza que el riesgo para los pacientes con score ECOG 2 o 3 aumenta entre 1.08 y 2.83 veces en comparación con pacientes con score ECOG 1



# Interpretación: Variable continua

- Relación entre la edad en el momento de diagnóstico y el tiempo de vida

```
> model3 <- coxph(Surv(time,status)~age,data=cancer)
> summary(model3)
Call:
coxph(formula = Surv(time, status) ~ age, data = cancer)

n= 228, number of events= 165

              coef exp(coef)  se(coef)      z Pr(>|z|)
age 0.018720    1.018897 0.009199  2.035   0.0419 *

      exp(coef) exp(-coef) lower .95 upper .95
age      1.019      0.9815    1.001    1.037
```

- **Interpretación:** Un año adicional en la edad de diagnóstico esta asociado con un incremento en el riesgo de 2 % (95%IC: 0.1-3.7,)



# Interpretación: Variable continua

- El aumento o disminución en el riesgo al comparar una personas de edad  $Z = a$  con una de edad  $Z = a + 10$  esta dado por

$$\frac{\lambda(t \mid Z = a + 10)}{\lambda(t \mid Z = a)} = \frac{\lambda_0(t)e^{0.02(a+10)}}{\lambda_0(t)e^{0.02a}} = e^{0.02 \times 10} = 1.22$$

- Interpretación:** Una diferencia de 10 años en la edad en el momento de diagnostico esta asociada con un incremento en el riesgo del 22%.
- Su intervalo de confianza al 95% esta dado por

```
> c(0.02*10 - 1.96*10*sqrt(model3$var), 0.02 + 1.96*10*sqrt(model3$var))
[1] 0.01969555 0.20030445
```

```
> exp(c(0.02*10 - 1.96*10*sqrt(model3$var), 0.02 + 1.96*10*sqrt(model3$var)))
[1] 1.019891 1.221775
```



# Interpretación: Modelo multivariado

- Modelo ajustado por edad, score ECOG y sexo del paciente

```
> model4 <- coxph(Surv(time,status)~age + sex + factor(ph.ecog),data=cancer)
> summary(model4)
```

```
n= 227, number of events= 164
(1 observation deleted due to missingness)
```

	coef	exp(coef)	se(coef)	z	Pr(> z )	
age	0.011031	1.011092	0.009297	1.186	0.23544	
sex	-0.551322	0.576188	0.167987	-3.282	0.00103	**
factor(ph.ecog) 1	0.409461	1.506006	0.199596	2.051	0.04022	*
factor(ph.ecog) 2	0.915752	2.498654	0.227042	4.033	5.5e-05	***

	exp(coef)	exp(-coef)	lower .95	upper .95
age	1.0111	0.9890	0.9928	1.0297
sex	0.5762	1.7355	0.4145	0.8009
factor(ph.ecog) 1	1.5060	0.6640	1.0184	2.2270
factor(ph.ecog) 2	2.4987	0.4002	1.6012	3.8991

- Después de controlar por el sexo del paciente y el score ECOG, la edad en el momento del diagnóstico no está asociado con el tiempo de vida del paciente ( $p = 0.24$ )



# Regresión: Multivariado

- Parte de interpretación

	<code>exp(coef)</code>	<code>exp(-coef)</code>	<code>lower .95</code>	<code>upper .95</code>
age	1.0111	0.9890	0.9928	1.0297
sex	0.5762	1.7355	0.4145	0.8009
<b>factor</b> (ph.ecog) 1	1.5060	0.6640	1.0184	2.2270
<b>factor</b> (ph.ecog) 2	2.4987	0.4002	1.6012	3.8991

- Sexo**: Las pacientes mujeres tienen 42% menos riesgo de morir (HR= 0.58, 95% IC: 0.41-0.80), comparación con los hombres, despues de controlar por otras variables
- Score ECOG**: Pacientes con score ECOG 2 o 3 tienen 2.5 veces el riesgo de morir en comparación con pacientes con score ECOG 0 (HR=2.5, 95%: 1.6 - 3.9)



# Regresión: Multivariado

## • Comparación de modelos

```
> model4 <- coxph(Surv(time,status)~age + sex + factor(ph.ecog),data=cancer)
> model5 <- coxph(Surv(time,status)~ sex + factor(ph.ecog),data=cancer)
> anova(model5,model4)
Analysis of Deviance Table

Cox model: response is Surv(time, status)
Model 1: ~ sex + factor(ph.ecog)
Model 2: ~ age + sex + factor(ph.ecog)
      loglik   Chisq Df P(>|Chi|)
1 -730.15
2 -729.44  1.4273  1    0.2322
```

## • Esta prueba evalúa la hipótesis

$$H_0 : \beta_{edad} = 0 \text{ vs. } H_0 : \beta_{edad} \neq 0$$

## • El estadístico es el cociente de *log verosimilitud*:

$$2[l_n(\text{modelo 4}) - l_n(\text{modelo 5})] \rightarrow_{H_0} \chi^2_{(1)}$$



# Estimación del riesgo basal

- Coeficientes de regresión se estiman usando la verosimilitud parcial
- Esta estimación se realiza sin necesidad de estimar la función de riesgo basal,  $\lambda_0(\cdot)$ .
- En algunos circunstancias es de interes estimar  $\lambda_0(\cdot)$ 
  - Estimamos interesados en la predicción del tiempo de sobrevida
  - Usar  $\lambda_0(\cdot)$  para explicar mejor las implicancias de nuestro modelo de riesgos proporcionales.



# Estimación del riesgo basal

- Recordemos que el modelo de Cox se expresa como

$$\lambda(t | Z) = \lambda_0(t) \exp [Z^t \beta]$$

que en base a la función de riesgo acumulada se expresa como

$$\Lambda(t | Z) = \Lambda_0(t) \exp [Z^t \beta]$$

y que es equivalente a

$$S(t | Z) = [S_0(t)]^{\exp [Z^t \beta]}$$

- La verosimilitud esta dada por

$$L_n(\beta, \lambda_0) = \prod_{i=1}^n [\lambda_0(x_i) e^{Z_i^t \beta}]^{\delta_i} \exp \left[ - \int_0^{x_i} \lambda_0(t) e^{Z_i^t \beta} dt \right]$$





# Estimación del riesgo basal

- Supongamos que observamos  $k$  eventos en tiempos distintos:  $t_1, \dots, t_k$
- Supongamos que conocemos el valor de  $\beta$ .
- La función de verosimilitud, en función de  $\lambda_0(\cdot)$ , nos sugiere:
  - Mirando el segundo factor. Quisieramos que  $\lambda_0$  sea lo mas pequeño posible.
  - Mirando el primer factor. Para observaciones  $\delta_i = 1$ , deseamos que el valor de  $\lambda_0(t_i)$  sea el mayor posible.
  - Podemos reducir el problema asumiendo que

$$\hat{\lambda}_0(t) = 0, \quad t \notin \{t_1, \dots, t_k\}$$

es decir para los puntos donde observamos censuras.



# Estimación del riesgo basal

- El logaritmo de la función de verosimilitud se reduce a

$$l_n(\lambda_0) = \sum_{i=1}^k [\log(\lambda_0(t_i)) + \mathbf{Z}_i^t \beta] - \sum_{i=1}^k \left( \lambda_0(t_i) \sum_{j \in R(t_i)} \exp \mathbf{Z}_j^t \beta \right)$$

donde  $R(t_i)$  es el conjunto de riesgo hasta antes del tiempo  $t_i$ .

- Si asumimos que  $\beta$  es conocido, tenemos  $k$  parámetros a estimar:

$$\lambda_0(t_1), \dots, \lambda_0(t_k)$$



# Estimación del riesgo basal

- El estimador de máxima verosimilitud para  $\lambda_0(t_i)$  es

$$\hat{\lambda}_0(t_i) = \frac{1}{\sum_{j \in R(t_i)} \exp(Z_j^t \hat{\beta})}$$

- La función de riesgo acumulada es

$$\hat{\Lambda}_0(t) = \sum_{t_i \leq t} \hat{\lambda}_0(t_i) = \sum_{t_i \leq t} \frac{1}{\sum_{j \in R(t_i)} \exp(Z_j^t \hat{\beta})}$$

que conocemos como el estimador de Breslow

- La función de supervivencia en base a este modelo es

$$\hat{S}_0(t) = e^{-\hat{\Lambda}_0(t)}$$

y es una función de saltos en los puntos  $\{t_1, \dots, t_k\}$



# Ejemplo: Cáncer

- Código de R

```
> model1 <- coxph(Surv(time,status)~sex,data=cancer)
> summary(model1)
```

```
n= 228, number of events= 165
```

```
      coef exp(coef) se(coef)      z Pr(>|z|)
sex -0.5310    0.5880    0.1672 -3.176  0.00149 **
```

- Al tener ambos estimadores  $\hat{\beta}$  y  $\hat{S}_0$ , podemos estimar la función de supervivencia


$$\hat{S}(t, \hat{\beta}) = [\hat{S}_0(t)]^{\exp(Z^t \hat{\beta})}$$

- En el caso de la variable historia reciente de consumo tenemos:

$$\begin{aligned}\hat{S}(t_i | \text{Hombre}) &= \hat{S}_0(t_i) \\ \hat{S}(t_i | \text{Mujer}) &= \hat{S}_0(t_i)^{\exp(0.32)}\end{aligned}$$



# Ejemplo: Cáncer



**Figure :** Función de supervivencia estimada bajo el modelo de proporcionalidad de Cox

# Ejemplo: Cáncer

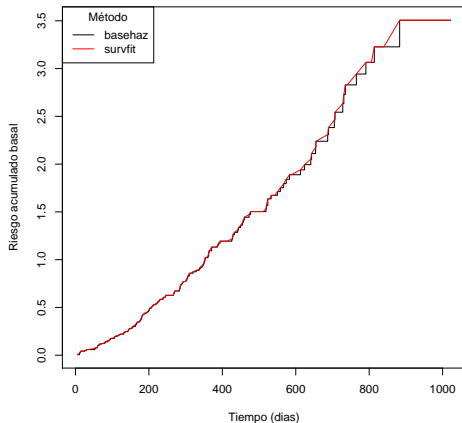


Figure : Función basal: Usando *basehaz* y *survfit*

# Función de supervivencia ajustada

- Supongamos que queremos estudiar las diferencias en el riesgo por sexo ajustando por edad

```
> model3 <- coxph(Surv(time,status)~age+sex,data=cancer)
> summary(model3)
Call:
coxph(formula = Surv(time, status) ~ age + sex, data = cancer)

n= 228, number of events= 165
```

	coef	exp(coef)	se(coef)	z	Pr(> z )
age	0.017045	1.017191	0.009223	1.848	0.06459 .
sex	-0.513219	0.598566	0.167458	-3.065	0.00218 **

	exp(coef)	exp(-coef)	lower .95	upper .95
age	1.0172	0.9831	0.9990	1.0357
sex	0.5986	1.6707	0.4311	0.8311

- Modelo

$$\Lambda(t | Z) = \Lambda_0(t)e^{0.02Z_1 - 0.51Z_2}$$

donde  $Z_1$  y  $Z_2$  son edad y sexo, respectivamente



# Funciones de supervivencia ajustadas

- Una idea popular es usar una medida de tendencia central de la variable de ajuste (Ejemplo: Media).

$$\hat{S}(t_i | \text{Hombre, edad} = 62.5) = \hat{S}_0(t_i)^{\exp(0.02 \times 62.5)}$$

$$\hat{S}(t_i | \text{Mujer, edad} = 62.5) = \hat{S}_0(t_i)^{\exp(-0.60 + 0.02 \times 62.5)}$$

- Estas dos curvas describen la experiencia de supervivencia, estimada por el modelo de Cox, para dos cohortes de sujetos de 63 años de edad (hombres y mujeres)
- En general para cualquier edad, la proporcionalidad entre las curvas se mantiene pero cada curva se reajusta en base a la edad.





# Ejemplo: Cancer




Figure : Función de supervivencia en base al modelo de Cox para una cohorte de hombres (negro) y mujeres (rojo) de 63 años de edad



# Ejemplo: Recaida en drogas

## ● Modelo multivariado

```
> model4 <- coxph(Surv(time, censor) ~ age + beck + race + treat + site, data = uis)
> summary(model4)
```

**Call:**

```
coxph(formula = Surv(time, censor) ~ age + beck + race + treat +
      site, data = uis)
```

n= 585, number of events= 471

(43 observations deleted due to missingness)

	coef	exp(coef)	se(coef)	z	Pr(> z )
age	-0.013638	0.986454	0.007506	-1.817	0.06921 .
beck	0.010255	1.010307	0.004831	2.123	0.03377 *
race	-0.309739	0.733638	0.111168	-2.786	0.00533 **
treat	-0.241273	0.785627	0.092667	-2.604	0.00922 **
site	-0.162555	0.849969	0.103407	-1.572	0.11595

	exp(coef)	exp(-coef)	lower .95	upper .95
age	0.9865	1.0137	0.9720	1.0011
beck	1.0103	0.9898	1.0008	1.0199
race	0.7336	1.3631	0.5900	0.9122
treat	0.7856	1.2729	0.6551	0.9421
site	0.8500	1.1765	0.6940	1.0409

## ● ¿Cómo presentamos graficamente estos resultados?



# Score de riesgo

- En un modelo con  $k$  covariables, el score de riesgo es definido por

$$\begin{aligned}\hat{r}_{\hat{\beta}}(\mathbf{Z}) &= \hat{\beta}_1 Z_1 + \hat{\beta}_2 Z_2 + \cdots + \hat{\beta}_k Z_k \\ &= \sum_{l=1}^k \hat{\beta}_l Z_l\end{aligned}$$

- El score de riesgo para el sujeto  $i$ -ésimo es

$$\hat{r}_j = \sum_{l=1}^k \hat{\beta}_l Z_{li}$$

que mide como la combinación de las covariables de una persona con estas características, afectan su riesgo.



# Score de riesgo




Figure : Distribución del score de riesgo

# Score de riesgo

- Función de supervivencia en base al score de riesgo

$$\hat{S}(t, \hat{r}_q) = \hat{S}_0(t)^{\exp(\hat{r}_q)}$$


donde  $\hat{r}_q$  corresponde a el  $q$ -ésimo cuantil empírico de los scores de riesgo.

- En el caso que quisieramos estudiar el efecto de una variable ajustando por el score de riesgo podemos definir

$$\hat{r}_{jl} = \hat{r}_j - \hat{\beta}_l Z_{jl}$$




## Ejemplo: Recaida en drogas



**Figure :** Función estimada de supervivencia en base a el score de riesgo



## Ejemplo: Recaida en drogas



**Figure :** Función estimada de supervivencia para los dos tipos de tratamiento ajustando por el score de riesgo

